



Федеральное государственное автономное образовательное
учреждение высшего образования
«Национальный исследовательский университет ИТМО»

ФАКУЛЬТЕТ «Программной инженерии и компьютерной техники»

ОБРАЗОВАТЕЛЬНАЯ ПРОГРАММА «Проектирование и разработка систем больших данных»

НАПРАВЛЕНИЕ ПОДГОТОВКИ (СПЕЦИАЛЬНОСТЬ) «09.04.04 Программная инженерия»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К КУРСОВОЙ РАБОТЕ

НА ТЕМУ:

«Определение сорта вина по описанию»

Обучающийся: Постнов С. А., Р4135
(Ф.И.О, № группы)

Руководитель курсовой работы Солодкая М. А., ассистент
(Ф.И.О, должность)

2026 г.

СОДЕРЖАНИЕ

1	Теоретическая часть	3
1.1	Метод опорных векторов (SVM)	3
1.2	Градиентный бустинг	3
2	Практическая часть	5
2.1	Данные	5
2.2	Разведочный анализ данных	5
2.3	Обучение моделей	7
2.4	Результаты	7
3	Вывод	10
A	Приложение	11

1 Теоретическая часть

1.1 Метод опорных векторов (SVM)

Метод опорных векторов (Support Vector Machine, SVM) — это алгоритм машинного обучения, основанный на поиске гиперплоскости, максимально разделяющей объекты разных классов. Для линейно разделимых данных задача формулируется как оптимизационная:

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{при условии} \quad y_i(w \cdot x_i + b) \geq 1, \quad \forall i$$

Для линейно неразделимых данных вводится штрафной параметр C и релаксационные переменные ξ_i :

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad \text{при условии} \quad y_i(w \cdot x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

Для нелинейной классификации используется «kernel trick» — замена скалярного произведения на ядерную функцию $K(x_i, x_j)$:

- Линейное ядро: $K(x_i, x_j) = x_i \cdot x_j$
- RBF-ядро (радиальная базисная функция): $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$
- Полиномиальное ядро: $K(x_i, x_j) = (\gamma \cdot x_i \cdot x_j + r)^d$

1.2 Градиентный бустинг

Градиентный бустинг — это ансамблевый метод, который строит последовательность слабых моделей (обычно деревьев решений), каждая из которых исправляет ошибки предыдущей. На каждой итерации t новая модель $h_t(x)$ обучается на псевдоостатках $r_i^{(t)}$, вычисленных как градиент функции потерь:

$$r_i^{(t)} = -\frac{\partial L(y_i, F_{t-1}(x_i))}{\partial F_{t-1}(x_i)}$$

Предсказание ансамбля обновляется:

$$F_t(x) = F_{t-1}(x) + \eta \cdot h_t(x)$$

, где η — скорость обучения (learning rate), контролирующая вклад каждого дерева.

HistGradientBoosting — оптимизированная реализация градиентного бустинга в scikit-learn, основанная на гистограммном подходе (аналог LightGBM). Дискретизация признаков в гистограммы позволяет значительно ускорить обучение на больших датасетах.

2 Практическая часть

2.1 Данные

В работе используется датасет `Wine Quality`, содержащий физико-химические характеристики португальских вин «Vinho Verde». Датасет включает два подмножества:

- Красное вино — 1599 экземпляров
- Белое вино — 4898 экземпляров

Каждый экземпляр описывается 11 числовыми признаками. Целевая переменная — сорт вина (0 — красное, 1 — белое). Пропусков в данных нет. Имеется небольшой дисбаланс классов: белое вино составляет около 75% выборки.

2.2 Разведочный анализ данных

Корреляционный анализ выявил следующие закономерности:

- Наиболее коррелированные с целевой переменной признаки: `total sulfur dioxide` (+0,70), `volatile acidity` (−0,65), `chlorides` (−0,51), `free sulfur dioxide` (+0,47), `fixed acidity` (−0,49), `sulphates` (−0,49).
- `Free sulfur dioxide` и `total sulfur dioxide` положительно коррелируют между собой.
- `Density` и `alcohol` имеют отрицательную корреляцию.
- `Density` положительно коррелирует с `fixed acidity` и `residual sugar`.

Корреляционная матрица представлена на рис. 2.1.

Распределения наиболее информативных признаков по классам показаны на рис. 2.2.




Рисунок 2.1 – Корреляционная матрица признаков




Рисунок 2.2 – Распределения признаков по классам (KDE)

2.3 Обучение моделей

Данные разделены на обучающую (75%) и тестовую (25%) выборки. Перед обучением применена стандартизация признаков (`StandardScaler`). Обучены следующие модели:

- 1) **Linear SVM**;
- 2) **RBF SVM**;
- 3) **Poly SVM**;
- 4) **Hist Gradient Boosting**.

2.4 Результаты

Метрики качества на тестовой выборке представлены в табл. 2.1.

Таблица 2.1 – Сравнение качества моделей

Модель	Accuracy	Precision	Recall	F1	ROC AUC
RBF SVM	0.9957	0.9952	0.9992	0.9972	0.9971
Hist Gradient Boosting	0.9932	0.9928	0.9984	0.9956	0.9960
Linear SVM	0.9920	0.9960	0.9936	0.9948	0.9911
Poly SVM	0.9914	0.9936	0.9952	0.9944	0.9936

Матрицы ошибок для каждой модели показаны на рис. 2.3.




Рисунок 2.3 – Матрицы ошибок для каждой модели

ROC-кривые представлены на рис. 2.4.




Рисунок 2.4 – ROC-кривые для различных моделей

3 Вывод

В результате работы можно сделать следующие выводы:

- 1) все четыре модели показывают высокое качество классификации (accuracy $> 0,99$), что объясняется хорошей разделимостью классов по физико-химическим признакам;
- 2) наилучший результат показал RBF SVM ($F1 = 0,9972$, ROC AUC = $0,9971$), что подтверждает эффективность нелинейного ядра для данной задачи;
- 3) Hist Gradient Boosting занимает второе место ($F1 = 0,9956$), демонстрируя высокое качество при минимальных настройках гиперпараметров;
- 4) Linear SVM и Poly SVM показывают сопоставимые результаты ($F1 \approx 0,994$), при этом линейный SVM имеет более высокую точность (precision), а поли-ядро — более высокую полноту (recall);
- 5) наиболее информативными признаками для определения сорта вина являются `total sulfur dioxide`, `volatile acidity` и `chlorides`.

А Приложение

Исходный код работы доступен в репозитории по ссылке:

<https://github.com/pstpn/ml/blob/main/course/main.ipynb>